Relatório do EP2

Classificação de clareza de respostas e-SIC

Disciplina: ACH2118 – Introdução ao Processamento de Língua Natural
Professor: Ivandré Paraboni
Projeto: stack-ivandre

1 Integrantes efetivos do grupo

Nome completo	Número USP
Aaron Ferraz do Amaral Martins da Silva	14554474
Geovanny Luan Piedade Barcelos	14573909
Valéria Caroline Silva	14677401
Kauê Camargo Marinho	14677422

2 Introdução e estratégia escolhida

O objetivo é classificar a clareza de respostas a pedidos de informação do e-SIC. A entrada é o texto da resposta (`resp_text`) e a saída é um dos três rótulos da coluna `clarity`: `c1` (nota 1), `c234` (notas 2 a 4) ou `c5` (nota 5).

O EP1 combinava BERTimbau e TF-IDF de palavras por média de probabilidades. O EP2 acrescenta um classificador de caracteres e aprende a combinação dos três modelos por **stacking**. Cada componente estima três probabilidades. A concatenação dessas nove entradas alimenta uma regressão logística multinomial, que atribui a classe de maior probabilidade.

3 Dados e pré-processamento

O treino contém 20.092 respostas, com 6.347 exemplos de `c1`, 6.853 de `c234` e 6.892 de `c5`. As divisões agrupam textos iguais após normalização Unicode NFC, `casefold` e colapso de espaços. Dentro da parcela destinada ao ajuste dos componentes, mantém-se a primeira ocorrência de cada par de texto exato e rótulo. Textos iguais com rótulos diferentes são preservados.

BERTimbau recebe o texto original, com preenchimento dinâmico e limite de 512 tokens, incluindo os especiais. Esse limite afeta 2.174 respostas do treino (10,82%). Os modelos lexicais recebem o texto inteiro em minúsculas, com frequência sublinear, IDF suavizado e normalização L2. A entrada se restringe à resposta textual. O pedido original e o conteúdo dos anexos ficam fora da representação.

A normalização identifica 18.143 grupos de textos no treino, dos quais 316 contêm mais de um rótulo. Ela serve para separar os grupos e não substitui o texto recebido pelo classificador. A deduplicação exata reduz o peso de cópias redundantes sem resolver por convenção as divergências de anotação.

4 Parâmetros e alternativas avaliados

O ponto de partida foi a média 50/50 entre BERTimbau e o modelo de palavras, estratégia do EP1. As alternativas variaram a forma de combinar as probabilidades e a inclusão do classificador de caracteres. A configuração de cada componente foi mantida fixa entre as comparações.

Estratégia	**Alternativas**
Classificador individual	BERTimbau, TF-IDF de palavras ou TF-IDF de caracteres.
Média dupla	Pesos iguais ou peso de BERTimbau em $\{0; 0{,}25; 0{,}50; 0{,}75; 1\}$. O peso de palavras é o complemento.
Média dupla calibrada	Uma temperatura por componente, no intervalo de 0,05 a 20, ajustada por perda logarítmica. Após a calibração, aplica-se a mesma grade de pesos.
Média tripla	Pesos iguais para os três componentes.
Stacking	Regressão logística multinomial sobre seis probabilidades (duplo) ou nove (triplo).

5 Configuração final escolhida

Componente	**Configuração**
BERTimbau	Base cased, seed 20260941, AdamW com taxa de aprendizado 2×10^{-5} e decaimento de pesos 0,01. Lote efetivo 8, 3.557 atualizações, agenda linear com horizonte de 4.702 passos e aquecimento de 470.
TF-IDF de palavras	Unigramas e bigramas. Regressão logística L2 com $C = 0{,}5$.
TF-IDF de caracteres	N-gramas de 3 a 5 caracteres dentro das palavras (`char_wb`). Regressão logística L2 com $C = 1$.
Vocabulário lexical	Frequência documental mínima de 3 e até 100.000 características por componente.
Stacking triplo	Regressão logística multinomial L2 com $C = 1$ e nove probabilidades brutas na ordem BERTimbau, palavras e caracteres.

Os dois modelos TF-IDF ajustam a regressão com o solver `lbfgs` e limite de 400 iterações. O combinador usa o mesmo solver com limite de 1.000 iterações. Para cada texto, as probabilidades de cada componente seguem a ordem `c1`, `c234`, `c5`. O combinador recebe esses valores diretamente e aplica uma transformação multinomial conjunta para produzir as três probabilidades finais.

6 Procedimento experimental

6.1 Separação dos dados e validação

O desenvolvimento usou 12 rodadas de validação estratificada por grupos com cinco folds. Cada fold foi dividido em três parcelas disjuntas por grupo.

Parcela	Fração aproximada	Função
Ajuste	64%	Ajuste de BERTimbau, dos vocabulários e dos classificadores lexicais após deduplicação.
Combinação	16%	Seleção de pesos, calibração e ajuste dos combinadores sobre previsões de componentes já treinados.
Avaliação	20%	Comparação dos modelos em grupos separados do ajuste e da combinação.

Os pesos das médias foram selecionados por acurácia em três subdivisões da parcela de combinação, com Macro F1 como desempate. Na alternativa calibrada, a temperatura de cada componente foi estimada nas subdivisões de ajuste e aplicada às subdivisões retidas. As temperaturas foram então ajustadas novamente na parcela completa de combinação. O stacking também foi ajustado nessa parcela. Dessa forma, os rótulos da avaliação externa ficaram separados das decisões de cada fold.

Cada linha integrou a avaliação externa uma vez por rodada. A acurácia da rodada usa todas as suas 20.092 previsões, e o resultado agregado é a média das 12 taxas. Os 60 ajustes do BERTimbau permitem observar a variação entre divisões. Como as rodadas reutilizam as mesmas respostas, as comparações entre rodadas são descritivas.

6.2 Ajuste final e previsão do teste

Na divisão final, uma partição estratificada de cinco blocos com seed 20269001 reservou um bloco para o combinador. Os demais blocos continham 15.991 linhas, das quais 15.035 permaneceram após a deduplicação. O combinador recebeu as previsões dos três componentes para as 4.101 respostas reservadas, sem interseção de grupos com o ajuste dos componentes.

Classe	Ajuste dos componentes	Ajuste da combinação
`c1`	4.582	1.321
`c234`	5.194	1.348
`c5`	5.259	1.432
Total	**15.035**	**4.101**

O pacote final gerou os 897 rótulos do teste 2. A planilha predita preserva a ordem das respostas e preenche a coluna `clarity`. O gabarito desse conjunto não está disponível, portanto a comparação de desempenho com o EP1 usa exclusivamente o teste 1.

7 Resultados do modelo final escolhido

7.1 Desenvolvimento

Modelo	Acurácia média	Macro F1 médio
BERTimbau	45,0876%	44,9667%
TF-IDF de palavras	44,7948%	44,4939%
TF-IDF de caracteres	44,4634%	44,2868%
Média 50/50 (estratégia do EP1)	45,9329%	45,7694%
Média dupla ponderada	45,9449%	45,7497%
Média dupla calibrada	45,9669%	45,7781%
Média tripla	46,1436%	45,9378%
Stacking duplo	46,1282%	45,7854%
Stacking triplo	**46,1830%**	45,8372%

O stacking triplo obteve a maior acurácia média, com vantagem de 0,2501 ponto percentual sobre a média 50/50 e melhora em 11 das 12 rodadas. A média tripla obteve o maior Macro F1. O stacking também apresentou menor erro de calibração que a média 50/50 (ECE de 0,01370 ante 0,04529).

Rodada	Média 50/50	Stacking triplo	Diferença (p.p.)
1	46,1826%	46,0482%	−0,1344
2	46,0979%	46,3169%	+0,2190
3	45,6052%	45,8839%	+0,2787
4	46,1328%	46,3767%	+0,2439
5	45,9088%	46,2970%	+0,3882
6	45,6699%	45,8043%	+0,1344
7	46,0930%	46,2025%	+0,1095
8	45,8292%	46,2821%	+0,4529
9	45,4957%	46,0382%	+0,5425
10	46,1328%	46,4862%	+0,3534
11	45,9337%	46,1776%	+0,2439
12	46,1129%	46,2821%	+0,1692

O ganho médio ficou abaixo da margem de simplicidade de 0,5 ponto percentual, pela qual a média 50/50 seria preferida. O modelo entregue é o stacking triplo, que teve a maior acurácia média entre as estratégias avaliadas. A diferença em relação ao stacking duplo foi de 0,0547 ponto percentual. Em desenvolvimento, o triplo aumentou o recall de `c1` e `c5`, enquanto o recall de `c234` caiu de 37,85% para 34,07%.

7.2 Comparação com o EP1 no teste 1

O pacote final foi comparado com as previsões originalmente entregues no EP1 nas mesmas 900 respostas, com 300 exemplos de cada classe.

Modelo	Acertos	Acurácia	Macro F1
EP1	443/900	49,22%	49,15%
EP2	462/900	51,33%	50,81%

	EP2 correto	EP2 incorreto
EP1 correto	378	65
EP1 incorreto	84	373

A melhora foi de 2,11 pontos percentuais, com 19 acertos adicionais no saldo. McNemar considera os 149 casos em que somente um modelo acertou. Sob a hipótese de acurácias marginais iguais, o número de acertos exclusivos de um modelo segue uma binomial com probabilidade 1/2, condicionada ao total de pares discordantes.

$$p = 2\sum_{k=0}^{65}\binom{149}{k}2^{-149} = 0{,}1401.$$

A estatística de McNemar sem correção é $(84-65)^2/149 = 2{,}4228$. A conclusão usa o teste exato bilateral. A diferença observada ficou aquém do nível de significância de 5%.

	EP1 (%)			EP2 (%)		
Classe	Precisão	Recall	F1	Precisão	Recall	F1
`c1`	51,45	47,33	49,31	52,19	55,67	53,87
`c234`	43,67	43,67	43,67	47,03	37,00	41,42
`c5`	52,47	56,67	54,49	53,49	61,33	57,14

As duas classes extremas ganharam recall. Para `c234`, a precisão aumentou e o recall caiu, com redução do F1. O Macro F1 do modelo subiu porque as duas outras classes compensaram essa perda.

O teste já havia sido usado em avaliações anteriores. Há 88 respostas idênticas a textos de treino e 105 após normalização. O próprio teste contém 12 grupos de textos exatos duplicados, dos quais dez têm rótulos conflitantes. A comparação mantém as 900 linhas entregues e deve ser interpretada como avaliação histórica, com dependência potencial entre as respostas.

7.3 Interpretação e análise de erros

No modelo de palavras da primeira divisão, os termos *demanda* e *não se* têm coeficientes positivos para `c1`, *sistemas* e *concurso* para `c234`, e *dnpm* e *questionário* para `c5`. Esses pesos refletem associações no conjunto de treino, inclusive vocabulário específico de órgãos e procedimentos.

A contribuição local de cada termo resulta do produto entre o TF-IDF e o coeficiente da classe. O escore do modelo de palavras é a soma dessas contribuições e do intercepto. A tabela mostra três erros da combinação selecionada nas divisões de desenvolvimento. Os índices começam em zero na planilha de treino.

Linha	Real	Prevista	Observação
6636	c5	c234	A resposta remete a anexos. O modelo de palavras acertou a classe e o termo *encaminhamos* contribuiu com +0,1179 para o escore de c5.
4056	c234	c1	A resposta combina justificativa de sigilo com informação parcial. Com 843 tokens, parte do conteúdo fica além do limite de BERTimbau.
10299	c5	c1	Uma resposta curta remete a protocolo anterior. A adequação do encaminhamento depende de contexto ausente da entrada.

O caso 6636 ilustra como a combinação pode errar mesmo quando um dos componentes acerta. Nos outros casos, o truncamento e a falta de contexto são hipóteses para explicar os erros observados. O escore lexical descreve apenas a decisão do componente de palavras.

8 Repositório de código

O código, os modelos ajustados, a configuração, as planilhas e as métricas agregadas estão disponíveis em `https://github.com/Zennitte/stack-ivandre`. As instruções de instalação, inferência e treinamento estão no `README.md`.

9 Instruções de reprodução

Com Python 3.12 e Git LFS, obtenha os pesos e instale as dependências. O exemplo usa o índice de rodas PyTorch para CPU.

```
git lfs pull
python -m pip install -r requirements.txt --extra-index-url https://download.pytorch.org/whl/cpu
python predict.py --input data/test.xlsx --sheet test2 --output predictions/nova_execucao.xlsx --
    device cpu
```

A saída preserva as linhas e o conteúdo original da planilha e preenche `clarity`. Para reconstruir o ajuste final, o README indica a revisão de BERTimbau, o ambiente CUDA e o comando `pyth ontrain.py`. O repositório inclui a divisão final e o manifesto dos pesos.