Relatório do EP2

Classificação de clareza de respostas e-SIC

Disciplina: ACH2118 – Introdução ao Processamento de Língua Natural
Professor: Ivandré Paraboni
Projeto: stack-ivandre

1 Integrantes efetivos do grupo

Nome completo	Número USP
Aaron Ferraz do Amaral Martins da Silva	14554474
Geovanny Luan Piedade Barcelos	14573909
Valéria Caroline Silva	14677401
Kauê Camargo Marinho	14677422

2 Introdução e estratégia escolhida

O objetivo é classificar a clareza de respostas a pedidos de informação do e-SIC. A entrada é o texto da resposta (`resp_text`) e a saída é um dos três rótulos da coluna `clarity`: `c1` (nota 1), `c234` (notas 2 a 4) ou `c5` (nota 5).

O EP1 combinava BERTimbau e TF-IDF de palavras por média de probabilidades. O EP2 acrescenta um classificador de caracteres e aprende a combinação dos três modelos por **stacking**. Cada componente estima três probabilidades. A concatenação dessas nove entradas alimenta uma regressão logística multinomial, que atribui a classe de maior probabilidade.

3 Dados e pré-processamento

O treino contém 20.092 respostas, com 6.347 exemplos de `c1`, 6.853 de `c234` e 6.892 de `c5`. As divisões agrupam textos iguais após normalização Unicode NFC, `casefold` e colapso de espaços. Dentro da parcela destinada ao ajuste dos componentes, mantém-se a primeira ocorrência de cada par de texto exato e rótulo. Textos iguais com rótulos diferentes são preservados.

BERTimbau recebe o texto original, com preenchimento dinâmico e limite de 512 tokens, incluindo os especiais. Esse limite afeta 2.174 respostas do treino (10,82%). Os modelos lexicais recebem o texto inteiro em minúsculas, com frequência sublinear, IDF suavizado e normalização L2. A entrada se restringe à resposta textual. O pedido original e o conteúdo dos anexos ficam fora da representação.

4 Parâmetros e alternativas avaliados

Foram comparados os três classificadores individuais, a média 50/50 do EP1, médias duplas com pesos selecionados, médias duplas com calibração, média tripla e stacking com dois ou três componentes. Nas médias duplas, o peso de BERTimbau foi escolhido entre 0, 0,25, 0,50, 0,75 e 1. A calibração ajustou temperaturas entre 0,05 e 20 por perda logarítmica. A configuração de cada componente foi mantida fixa entre as comparações.

5 Configuração final escolhida

Componente	Configuração
BERTimbau	Base cased, seed 20260941, AdamW com taxa de aprendizado 2×10^{-5} e decaimento de pesos 0,01. Lote efetivo 8, 3.557 atualizações, agenda linear com horizonte de 4.702 passos e aquecimento de 470.
TF-IDF de palavras	Unigramas e bigramas. Regressão logística L2 com $C = 0{,}5$.
TF-IDF de caracteres	N-gramas de 3 a 5 caracteres dentro das palavras (`char_wb`). Regressão logística L2 com $C = 1$.
Vocabulário lexical	Frequência documental mínima de 3 e até 100.000 características por componente.
Stacking triplo	Regressão logística multinomial L2 com $C = 1$ e nove probabilidades brutas na ordem BERTimbau, palavras e caracteres.

6 Procedimento experimental

6.1 Separação dos dados e validação

O desenvolvimento usou 12 rodadas de validação estratificada por grupos com cinco folds. Em cada fold, cerca de 64% dos dados foram reservados ao ajuste dos componentes, 16% à combinação e 20% à avaliação. Os grupos foram mantidos separados entre as três parcelas. Os pesos e temperaturas das alternativas foram selecionados em três subdivisões da parcela de combinação. Cada linha integrou a avaliação uma vez por rodada. As médias entre rodadas são descritivas, pois as rodadas reutilizam as mesmas respostas.

6.2 Ajuste final e previsão do teste

Os três componentes finais foram ajustados em 15.035 respostas após deduplicação. O combinador foi ajustado em outras 4.101 respostas de grupos distintos, usando as probabilidades dos componentes já treinados. O pacote final gerou os 897 rótulos do teste 2, cujo gabarito não está disponível.

7 Resultados do modelo final escolhido

7.1 Desenvolvimento

Modelo	Acurácia média	Macro F1 médio
BERTimbau	45,0876%	44,9667%
TF-IDF de palavras	44,7948%	44,4939%
TF-IDF de caracteres	44,4634%	44,2868%
Média 50/50 (estratégia do EP1)	45,9329%	45,7694%
Média tripla	46,1436%	45,9378%
Stacking duplo	46,1282%	45,7854%
Stacking triplo	**46,1830%**	45,8372%

O stacking triplo obteve a maior acurácia média, com vantagem de 0,2501 ponto percentual sobre a média 50/50 e melhora em 11 das 12 rodadas. A média tripla obteve o maior Macro F1. O stacking também apresentou menor erro de calibração que a média 50/50 (ECE de 0,01370 ante 0,04529).

7.2 Comparação com o EP1 no teste 1

O pacote final foi comparado com as previsões originalmente entregues no EP1 nas mesmas 900 respostas, com 300 exemplos de cada classe.

Modelo	Acertos	Acurácia	Macro F1
EP1	443/900	49,22%	49,15%
EP2	462/900	51,33%	50,81%

Os dois modelos acertaram 378 respostas e erraram 373. Apenas o EP1 acertou 65 respostas e apenas o EP2 acertou 84. A melhora foi de 2,11 pontos percentuais. O teste de McNemar exato bilateral resultou em $p = 0{,}1401$ (estatística descritiva sem correção de 2,4228). A diferença observada ficou aquém do nível de significância de 5%.

O recall de `c1` passou de 47,33% para 55,67%, e o de `c5` de 56,67% para 61,33%. Para `c234`, caiu de 43,67% para 37,00%. O teste já havia sido usado em avaliações anteriores. Há 88 respostas idênticas a textos de treino, 105 após normalização, além de duplicatas e rótulos conflitantes no próprio teste. Esses fatores limitam a interpretação da comparação como evidência de generalização.

7.3 Interpretação e análise de erros

No modelo de palavras da primeira divisão, os termos *demanda* e *não se* têm coeficientes positivos para `c1`, *sistemas* e *concurso* para `c234`, e *dnpm* e *questionário* para `c5`. Esses pesos refletem associações no conjunto de treino, inclusive vocabulário específico de órgãos e procedimentos.

A contribuição local de cada termo resulta do produto entre o TF-IDF e o coeficiente da classe. Em uma resposta que remetia a anexos (linha 6636, com índice iniciado em zero), *encaminhamos* contribuiu com +0,1179 para o escore de `c5`. O classificador de palavras acertou a classe, enquanto a combinação selecionada naquele fold previu `c234`. Em outra resposta, uma justificativa de sigilo acompanhava informação parcial. A combinação previu `c1` para um exemplo de `c234`. O texto excedia 512 tokens, e o pedido original seria necessário para avaliar a adequação da resposta.

8 Repositório de código

O código, os modelos ajustados, a configuração, as planilhas e as métricas agregadas estão disponíveis em `https://github.com/Zennitte/stack-ivandre`. As instruções de instalação, inferência e treinamento estão no `README.md`.

9 Instruções de reprodução

Com Python 3.12 e Git LFS, obtenha os pesos e instale as dependências. O exemplo usa o índice de rodas PyTorch para CPU.

```
git lfs pull
python -m pip install -r requirements.txt --extra-index-url https://download.pytorch.org/whl/cpu
python predict.py --input data/test.xlsx --sheet test2 --output predictions/nova_execucao.xlsx --
    device cpu
```

A saída preserva as linhas e o conteúdo original da planilha e preenche `clarity`. O código de ajuste final, o split e a revisão do pré-treinado constam no repositório.